

DOI:10.13228/j.boyuan.issn0449-749x.20250088

基于特征选择的 SHAP-Transformer 高炉铁水硅含量预报模型

马居安¹, 郑华伟², 刘栋梁², 陆 昊¹, 周进东¹, 毕学工¹, 熊 玮¹

(1. 武汉科技大学钢铁冶金及资源利用省部共建教育部重点实验室, 湖北 武汉 430081;

2. 武汉钢铁有限公司炼铁厂, 湖北 武汉 430080)

摘 要: 数据驱动方法在高炉铁水硅含量预报方面取得了一定的成功,但由于高炉的复杂性,特征参数的强耦合、大时滞和多时间尺度特点提高了模型的训练难度,这是硅预报模型应用需要持续研究和特别关注的问题。采用时间窗口和主成分分析(principal component analysis,PCA)将22个分钟级的特征参数转化为铁次级参数,进一步采用滑动窗口和最大信息系数(maximal information coefficient, $C_{\max}$)确定了参数的滞后时长。利用随机森林优化的SHAP算法对34个参数在强耦合条件下的重要性进行评估,筛选出7个关键参数。使用SHAP算法优化Transformer的自注意力机制,构建了SHAP-Transformer铁水硅含量预报模型,通过现场数据验证了模型的有效性。结果表明,铁水硅质量分数预测误差为 $-0.05\sim 0.05$ 和 $-0.1\sim 0.1$ 时,基于滑动窗口时滞分析及耦合参数优选的SHAP-Transformer模型的命中率最高,分别为72.12%和95.76%,比基于MIC参数选择的SHAP-Transformer模型提高了26.67%和21.21%,比基于滑动窗口时滞分析及耦合参数优选的长短时记忆网络(long short-term memory,LSTM)模型提高了17.57%和9.7%。基于滑动窗口时滞分析及耦合参数优选的SHAP-Transformer模型对铁水硅含量的变化趋势预测也有较高的精度,趋势方向预测的准确率为87.3%,趋势类别预测的准确率为60.5%,研究能够为高炉操作者提前判断炉温变化提供可靠依据。

关键词: 高炉; 铁水硅含量; 特征选择; 时滞分析; 随机森林; SHAP算法; 炼铁; 预报模型

文献标志码: A **文章编号:** 0449-749X(2025)08-0068-11

Prediction model for silicon content of hot metal in blast furnace based on feature selection and SHAP-Transformer

MA Ju'an¹, ZHENG Huawei², LIU Dongliang², LU Hao¹, ZHOU Jindong¹,
BI Xuegong¹, XIONG Wei¹

(1. Key Laboratory for Ferrous Metallurgy and Resources Utilization of Ministry Education,
Wuhan University of Science and Technology, Wuhan 430081, Hubei, China; 2. Ironmaking Plant,
Wuhan Iron and Steel Co., Ltd., Wuhan 430080, Hubei, China)

Abstract: Data-driven approaches have achieved notable success in predicting the silicon content of hot metal in blast furnaces. Due to the complexity of the blast furnace, blast furnace data possesses strong coupling, large time delays, and multi-timescale characteristics, which make model training more challenging. It should be continuing researched and paid particular attention. A time windowing technique combined with principal component analysis (PCA) was employed to transform 22 minute-level features into heat-level parameters. A sliding window approach and the maximal information coefficient ($C_{\max}$) were then used to determine the optimal lag time for each parameter. To evaluate parameter importance under strong coupling conditions, a SHAP algorithm optimized with a random forest model was applied to 34 parameters, identifying 7 key influencing factors. Furthermore, SHAP was utilized to refine the self-attention mechanism of the transformer model, resulting in the development of the SHAP-Transformer model for predicting hot metal silicon content. The validity of the proposed model was checked using industrial data. The results showed that the SHAP-Transformer model, incorporating sliding window-based lag analysis and optimal coupled parameter selection, achieves the highest prediction accuracy. The hit rates of the prediction model within error ranges of $-0.05\sim 0.05$ and $-0.1\sim 0.1$ were 72.12% and 95.76%, respectively, surpassing the SHAP-Transformer model based on MIC-selected parameters by 26.67% and 21.21%, and outper-

基金项目: 国家自然科学基金重点资助项目(61933015);“十四五”湖北省优势特色学科(群)资助项目(2023B0302)

作者简介: 马居安(1998—),男,硕士生; **E-mail:** mza657@163.com; **收稿日期:** 2025-03-04

通信作者: 熊 玮(1975—),男,博士,教授; **E-mail:** xiongwei@wust.edu.cn

forming the long short-term memory (LSTM) model with sliding window-based lag analysis and optimal coupled parameter selection by 17.57% and 9.7%. Moreover, the proposed SHAP-Transformer model exhibits high accuracy in forecasting silicon content trends, achieving 60.5% accuracy in trend classification and 87.3% accuracy in trend direction prediction. The model can provide a reliable basis for blast furnace operators to forecast temperature fluctuations and optimize furnace operation proactively.

Key words: blast furnace; silicon content in hot metal; feature selection; time lag analysis; random forest; SHAP algorithm; ironmaking; prediction model

高炉铁水中的硅含量是评估铁水质量及炉内热状态的关键参数之一^[1],硅含量的波动能间接反映高炉整体的运行状态,是操作人员进行操作参数调整的一项重要依据^[2]。实现硅含量的准确预测对提高铁水质量、辅助参数调整以及降低生产成本具有重要意义。

传统的硅含量预测方法主要依靠专家经验和基于机理的统计模型,对高炉复杂工况的描述能力有限,难以满足现代高炉生产的需求^[3-8]。随着计算机科学、大数据处理和人工智能技术的发展,基于数据驱动的预报方法受到了前所未有的重视,将数学方法和专家知识相结合构建机器学习模型,挖掘高炉操作参数与铁水硅含量间的非线性映射关系,为实现铁水硅含量的精准预测提供了新的思路^[9]。

近年来,针对高炉数据存在的大时滞特性和动态工况特征,以长短时记忆网络(long short-term memory, LSTM)为代表的时间序列模型因其在处理时序数据方面具有独特优势,被广泛应用于铁水硅预报工作^[10-13]。李泽龙等^[14]提出了一种结合历史信息与实时数据的LSTM-RNN预测模型,能够准确捕捉硅含量的变化趋势;REN Y Z等^[15]通过粒子群优化算法(particle swarm optimization, PSO)优化时序卷积网络(temporal convolutional network, TCN)模型的初始权重,有效提高了预测的准确性和稳定性。此外,高炉生产过程中的变量众多,其中可能包含大量无关或冗余信息,直接将其用于模型构建,不仅会增加模型的结构复杂性,还会提高学习难度,影响模型性能和实用性。针对这一问题,尹林子等^[16]通过k-means++算法进行特征优选后与LSTM模型相结合,有效提升了模型的鲁棒性和泛化能力;邱国兴等^[17]采用灰色关联分析(grey relational analysis, GRA)和主成分分析(principal component analysis, PCA)对输入特征进行筛选和降维,进一步优化了LSTM模型的预测能力。

众多研究表明,通过优化模型输入特征和改进算法结构,可以显著提升模型性能及实用性。但是,当前研究仍存在一些不足亟待解决。一方面,

高炉生产过程涉及的变量众多,且变量之间存在强耦合关系,只依靠算法本身的无监督学习难以充分考量高炉数据间的强耦合关系,导致模型泛化能力下降^[18]。另一方面,LSTM等传统时间序列模型在捕捉序列长距离依赖时往往会面临梯度消失的问题,导致模型预测精度随着时间推移而逐渐下降^[19-21]。

针对上述问题,本文首先构建了融合时滞分析与耦合参数优选的预处理框架,通过将滑动窗口、PCA与最大信息系数(maximal information coefficient, MIC)相结合,量化各参数的滞后时间,优化输入特征的动态相关性;同时,利用随机森林优化的SHAP算法得出耦合条件下的参数重要性排名并依此进行数据优选,增强模型鲁棒性。进一步,为了解决传统时间序列模型的梯度消失问题,本文引入Transformer模型,依靠其全局自注意力机制来捕捉参数间的全局依赖关系^[22],并通过SHAP优化策略,增强模型对局部特征的捕捉能力^[23]。

1 参数选取

高炉炼铁过程如图1所示。高炉炼铁过程是复杂的多变量动态系统,高炉炼铁原料从入炉到出铁通常需要6~8 h,炉料状态从固态向熔融态、液态转变,各参数对铁水中硅含量的影响程度随着炉料的下降而发生变化^[24],主要影响时间往往与出铁时间(硅含量检测时间)不一致,导致产生不同的滞后时长。

铁水硅含量预报模型参数的选取需要结合高炉冶炼原理及数据特征,高炉内硅的还原受炉缸状态、煤气流动、送风制度等多种因素协同影响。富氧率、热风温度、鼓风动能、理论燃烧温度等参数表征了高炉炉缸热状态和反应环境,影响硅的还原动力;煤气利用率、边缘气流指数等参数反映了炉内热交换效率与炉内温度分布;炉渣碱度、渣中CaO、MgO、Al₂O₃、FeO等成分含量表征了炉渣的理化性能,影响渣的氧势及硅在渣铁间的分配比。此外,




图 1 高炉炼铁过程

Fig. 1 Schematic of blast furnace smelting

铁水成分中的 Mn、S 等元素含量也与硅还原的热力学平衡及化学反应路径密切相关。

为了探索各参数与铁水硅含量的关联情况,本文结合高炉冶炼流程,采集了某铁厂 6 号高炉实时数据库 1 年左右记录数据,涵盖送风条件、冷却条件、生产参数、煤气成分、炉渣成分及铁水成分等,选择 35 个参数用于时滞分析与参数优选,各参数代号及名称见表 1。对原始数据库中的数据进行数据清洗、过滤处理,转换为高质量的数据。对于缺失数据根据时间的相关关系使用样条插值法填补缺失值;对于异常数据,采用 2% 的箱线图剔除休风、停炉时的无效数据和极端值。最后得到了 527 016 条分钟级数据及 3 340 条铁次级数据(高炉每次出铁才检测的数据,称为铁次级数据)。

2 时滞分析与耦合参数优选

为了强化模型在复杂工业场景下的预测能力,模型训练前的数据分析与预处理工作具有重要意义^[25-26]。通过优化输入特征,消除大量的无效信息干扰,可以使模型接收到的每个参数与铁水硅含量在时间和数值上均保持高度的相关性,减少模型在训练过程中对时序依赖关系的学习负担^[27-28],使其能够更快速、更有效地得到高炉铁水硅含量与参数之间的非线性关系。而且,简化模型输入结构后,模型训练复杂性得以降低,减少了过拟合风险,提高了模型的可解释性^[29]。基于此,本文深入解析了高炉数据的滞后与耦合关系,为模型训练打下了良好基础。

表 1 参数选择

Table 1 Parameter selection

Category	Parameter	Parameter code
Process parameters	Oxygen enrichment ratio/%	X1
	Blast kinetic energy/(g·m·s ⁻¹)	X2
	Hot air pressure/kPa	X3
	Hot air temperature/°C	X4
	Cold blast flow rate/(m ³ ·h ⁻¹)	X5
	Blast humidity/(g·m ⁻³)	X6
	Theoretical combustion temperature/°C	X7
	Coal injection rate/(kg·h ⁻¹)	X8
	Bosh gas index	X9
	Gas utilization rate/%	X10
	Edge gas flow index	X11
	Top pressure/kPa	X12
	Temperature of throat steel brick/°C	X13
	Riser gas temperature/°C	X14
	Average pressure in furnace/kPa	X15
	Permeability index	X16
	Softened water outlet temperature/°C	X17
	Softened water inlet temperature/°C	X18
Gas composition	φ(CO)/%	X19
	φ(CO ₂)/%	X20
	φ(N ₂)/%	X21
	φ(H ₂)/%	X22
Slag composition	w(SiO ₂)/%	X23
	w(CaO)/%	X24
	w(S)/%	X25
	w(FeO)/%	X26
	w(MgO)/%	X27
	w(Al ₂ O ₃)/%	X28
	Binary basicity of slag	X29
Hot metal composition	w(Si)/%	X30
	w(Mn)/%	X31
	w(S)/%	X32
	w(P)/%	X33
	w(Ti)/%	X34
	w(Cr)/%	X35

2.1 基于滑动窗口的时滞分析

选取的参数中, $X1 \sim X22$ 为分钟级数据, 而铁水硅含量为铁次级数据, 数值仅在新的出铁开始时更新, 两者间的时间尺度不统一, 直接进行相关分析会导致结果失真^[30]。本文采用时间窗口方法解决时间尺度不一致的问题, 时间窗口划分如图 2 所示。首先依据出铁间隔时长(2 次出铁开始之间的时间间隔)构建与之大小对应的时间窗口, 再利用取平均值等方法, 可以实现窗口内数据由分钟级到铁次级的转化。通过滑动时间窗口可以使整合出的铁次级数据具有不同程度的滞后时长。

对用作相关性分析的参数简单取平均值会导致参数在窗口内的波动幅度大小等特征信息丢失^[31]。为了尽可能保留参数在窗口内的数据信息, 本文提取每条分钟级参数在时间窗口内的平均值、最大值、最小值、方差及移动平均斜率, 使用主成分分析(PCA)技术对这些特征进行降维, 将其变为铁次级的一维综合特征参数。

考虑 6 h 内的滞后情况, 设定了 24 个时间步,




图 2 时间窗口划分
Fig. 2 Time window division

每个时间步间隔为 15 min。在每个时间步分别计算各综合特征参数与铁水硅含量之间的 C_{imax} , 得到的 C_{imax} 分布情况如图 3 所示, 图右侧为颜色条, 用于指示热力图中颜色与 C_{imax} 之间的对应关系, 便于直观判断各参数在不同滞后步数下的相关强度。横坐标为时间滞后步数, 纵坐标为参数代号, C_{imax} 越大表明相关性越高。依据各参数在合理滞后时长范围内 C_{imax} 对应的滞后步数确定其滞后时长, 最终得出 $X1 \sim X22$ 的滞后时长见表 2。




图 3 分钟级参数滞后步数的 C_{imax}

Fig. 3 C_{imax} distribution of parameters and hot metal silicon content at different lag steps

表 2 分钟级参数滞后时长

Table 2 Lag time of minute-level parameters

Parameter name	Parameter code	Lag time/h
Oxygen enrichment ratio/%	X1	2.75
Blast kinetic energy/(g·m·s ⁻¹)	X2	1.25
Hot air pressure/kPa	X3	1.50
Hot air temperature/°C	X4	1.25
Cold blast flow rate/(m ³ ·h ⁻¹)	X5	1.25
Blast humidity/(g·m ⁻³)	X6	0.75
Theoretical combustion temperature/°C	X7	3.00
Coal injection rate/(kg·h ⁻¹)	X8	1.75
Bosh gas index	X9	1.25
Gas utilization rate/%	X10	0.75

续表 2

Parameter name	Parameter code	Lag time/h
Edge gas flow index	X11	0.75
Top pressure/kPa	X12	0.50
Temperature of throat steel brick/℃	X13	4.25
Riser gas temperature/℃	X14	1.50
Average pressure in furnace/kPa	X15	0.75
Permeability index	X16	0.50
Softened water outlet temperature/℃	X17	3.00
Softened water inlet temperature/℃	X18	3.00
$\varphi(\text{CO})/\%$	X19	0.75
$\varphi(\text{CO}_2)/\%$	X20	0.75
$\varphi(\text{N}_2)/\%$	X21	2.50
$\varphi(\text{H}_2)/\%$	X22	2.25

2.2 基于随机森林优化 SHAP 值的耦合参数优选

不恰当的参数选择不仅会增加模型的计算成本,还会导致模型的泛化能力下降,所以合适的参数选择十分重要^[32-33]。本模型输入参数的选取需妥善处理数据层面的 2 个关键问题,即参数间的强耦合性以及非线性关系。

现阶段大多使用 C_{imax} 、皮尔逊相关系数等一对一的方法分析相关性,按照计算所得的相关系数高低作为最终的参数确定依据。但是,一对一的相关性计算方法忽视了各参数间的协同作用关系^[34-35],某一参数的相关系数无法体现该参数与其他参数耦合后的重要程度,而以 Shapley 值为基础的 SHAP 算法考虑了数据间的耦合性。

Shapley 值是基于博弈论概念,将预测结果视为多个特征合作产生的总效应^[36],能够量化每个特征对预测目标的边际贡献。Shapley 值的计算方法见式(1)。

$$\phi_i = \sum_{S \subseteq F, \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup \{i\}) - f(S)] \quad (1)$$

式中: ϕ_i 为特征 i 的 Shapley 值; F 为所有特征的集合; S 为特征子集; $f(S)$ 为特征子集 S 对模型输出的贡献值; $\{i\}$ 为特征 i 的整体数据集。

SHAP 算法基于 Shapley 值,通过对所有特征的组合及其边际贡献的整合生成全局的特征重要性评估结果。此外,还使用随机森林算法对 SHAP 算法进行优化,处理高炉参数间的非线性关系^[37]。

耦合参数优选的计算流程如图 4 所示。在随机森林中,每棵树都会生成一组局部特征重要性评估值,SHAP 算法通过整合森林中所有树的分裂路径信息,计算出各参数对铁水硅含量的真实贡献值。

将样本数据对齐滞后时长后,计算得到随机森林优化后的 Shapley 值 ϕ ,依据 SHAP 算法对 34 个参数与铁水硅含量的相关性进行排名,前 20 名如图 5 所示。将煤气利用率、CO 含量、炉腹煤气量指数、




图 4 耦合参数优选流程

Fig. 4 Coupled parameter selection process

透气性指数、理论燃烧温度、热风温度及炉喉钢砖温度7个Shapley值大于0.1的参数与铁水硅含量作为模型输入。值得注意的是,时间序列算法在运算过程中会充分考虑到规定时间窗口内前数个时间步的输入参数,因此无需将前一次出铁的铁水硅含量作为额外的影响因素引入模型。




图5 基于随机森林-SHAP算法的参数重要性排名

Fig. 5 Importance ranking based on random forest-SHAP analysis

3 SHAP-Transformer模型

高炉生产过程中存在一些长期缓慢变化的非操作因素,这些变化会持续影响参数与铁水硅含量间的映射关系。在基于时间序列的高炉铁水硅预报模型中,许多传统模型如自回归移动平均模型(autoregressive integrated moving average model, ARIMA)假设当前状态只依赖于最近的几个时间点,忽略了更早的历史信息;循环神经网络(recurrent neural network, RNN)在训练过程中,梯度通过时间反向传播时会逐渐衰减(消失)或放大(爆炸),难以有效捕捉参数间的长期时序依赖;LSTM模型虽然通过门控机制缓解了梯度消失问题,能够捕捉一定程度的长期依赖关系,但在处理极长序列时,其性能仍然受限。Transformer通过全局视野、动态权重分配和并行计算,对于任意2个位置的参数,无论它们相隔多远都能够直接捕捉到序列中任意2个位置之间的长依赖关系^[38]。

VASWANI A等^[39]提出的Transformer模型不是顺序处理输入数据,而是通过多头注意力机制(multi-head attention)有效捕获输入序列中的全局特征并生成预测值,所以在高炉非操作因素发生变化时,模型能够维持稳定。Transformer模型结构如图6所示,主要包括嵌入层、编码器、解码器、线性变换和SoftMax层。




图6 Transformer模型结构

Fig. 6 Structure of Transformer model

3.1 基于位置编码的时序优化

在标准的时间序列建模方法中,数据间的时间间隔通常是均匀的。然而,高炉铁水硅含量是铁次级数据,数值仅在新的一次出铁开始时更新,由于出铁更新间隔时长不固定,会导致铁水硅含量数据的时间间隔不均匀。不均匀的时间间隔会导致模型无法准确捕捉到数据的变化规律,使预测结果出现偏差^[40]。

Transformer模型可以通过位置编码解决这一问题,位置编码通过为输入数据添加位置向量来表示数据在序列中的相对或绝对位置。即使输入数据之间的时间间隔不均匀,模型仍能够通过位置编码捕捉到各个数据点之间的顺序关系,确保不同时间间隔的数据能够得到恰当的处理和关联,从而解决相邻铁水硅含量数据间隔时长不固定的问题。

3.2 Transformer的多头自注意力机制

Transformer的多头自注意力机制可以视作对序列数据中各位置间的相似性计算。假设输入序列为 $X = \{x_1, x_2, \dots, x_n\}$,每个位置上的向量 x_i 经过线性变换生成查询(query)、键(key)和值(value)向量,分别记为 Q 、 K 和 V 。各位置间注意力权重 $\text{Attention}(Q, K, V)$ 的计算公式为

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2)$$

式中: $\text{softmax}()$ 为归一化指数函数; d_k 为键向量的维度, 用于缩放内积, 以避免在高维空间中出现的梯度消失或爆炸的情况。

通过多头机制, Transformer 将注意力分解为多个子空间, 使模型能够同时关注到不同位置和特征之间的关系, 从而增强了其对全局依赖的捕捉能力。

3.3 SHAP 优化的多头自注意力机制

Transformer 模型虽然在全局依赖关系的建模上表现出色, 但在处理局部特征时往往关注度不足, 这是因为多头自注意力机制主要通过位置间的相似性来分配注意力权重, 而没有依据特征对预测任务的实际贡献度进行调整, 可能导致局部信息波动被忽视, 无法充分利用所有数据细节进行预测分析。

为了解决这一问题, 本文使用 SHAP 算法优化

Transformer 的自注意力机制, 利用 Shapley 值来量化各输入特征对预测结果的贡献, 帮助识别并增强对预测结果影响较大的局部特征。具体而言, 首先基于 Shapley 值得到不同时间步上各参数的贡献度, 并将其表示为权重矩阵 S , 然后在注意力计算中利用该权重矩阵对注意力得分进行调整, 如图 7 所示。优化后的注意力权重 $\text{Attention}_{\text{SHAP}}(Q, K, V, S)$ 计算公式为

$$\text{Attention}_{\text{SHAP}}(Q, K, V, S) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}} * S\right)V \quad (3)$$

式中: $*$ 为逐元素乘法操作; S 为 Shapley 值形成的加权矩阵。

引入 Shapley 值后, 模型能够在注意力计算中对局部关键参数赋予更高的权重, 从而在不改变原有模型结构的基础上增强 Transformer 对局部特征的捕捉能力。




图 7 SHAP 算法优化的注意力机制

Fig. 7 Attention mechanism optimized by SHAP

4 结果分析及比较

分别使用基于 MIC 参数选择的 SHAP-Transformer 模型, 基于滑动窗口时滞分析与耦合参数优选的 LSTM 模型与基于滑动窗口时滞分析与耦合参数优选的 SHAP-Transformer 模型将特征参数及铁水硅含量代入模型进行训练。考虑到预测

模型的时间窗口机制, 在计算过程中可以同时融合当前及多个历史时间步上的输入参数, 所以预报提前时间对比了输入参数的基准滞后时长, 透气性指数的滞后时长是所有参数中最短的, 为 0.5 h, 为了不丢失该参数的关键信息, 模型预测硅含量的提前时间设为 0.5 h。得到 3 种模型最优的超参数值见表 3。

表 3 模型超参数设置

Table 3 Model hyperparameter settings

Model	Hidden layer count	Attention head count	Feedforward network unit count	Time window length	Learning rate
MIC+SHAP-Transformer	64	8	128	8	0.000 5
Feature selection+LSTM	64	—	—	12	0.001 0
Feature selection+SHAP-Transformer	64	4	128	6	0.000 5

4.1 铁水硅含量预测结果的准确度对比

选用命中率 H 、均方根误差 R_{MSE} 、决定系数 R^2 及平均绝对误差 R_{MAE} 作为评价模型预测性能的指

标, 评价指标的计算公式见式(4)~式(7)。

$$H = \frac{1}{N} \sum_{i=1}^N I(|\hat{y}_i - y_i| \leq \epsilon) \quad (4)$$

$$R_{\text{MSE}} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2}$$

(5)

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$$

(6)

$$R_{\text{MAE}} = \frac{1}{N} \sum_{i=1}^N \frac{|y_i - \hat{y}_i|}{|y_i|}$$

(7)

式中: N 为样本总数; I 为指示函数; $\hat{y}_i$ 为第*i*个样本的预测值; y_i 为第*i*个样本的真实值; $\bar{y}$ 为样本均值; ϵ 为允许的误差范围。


使用前面 95% 的铁次级数据(3 179 条)用于模型训练,其余 5% 数据(161 条)作为验证集,得到 3 种模型的预测结果如图 8 所示,评价指标结果见表 4。

高炉是一个封闭的高压逆流反应器,存在诸多相互影响因素,不可能完全探知到,还存在很多不可预知的地方,一点轻微变化都有可能产生蝴蝶效应,引起炉况的变化和铁水硅含量的波动。由图 8 可见,时滞分析及耦合参数优选显著增强了模型在铁水硅含量发生剧烈波动时的预测能力。当测试样本标号在[20, 30]时,实际铁水硅含量出现明显的快速上升和下降,基于 C_{imax} 选择的 SHAP-Transformer 模型的预测硅值滞后或偏离实测值的情况十分明显,而基于时滞分析及耦合参数优选的 LSTM 模型和 SHAP-Transformer 模型能够较好地捕捉到这种复杂的变化状态,大幅提升了模型在铁水硅含量剧烈波动时间段的预测精度。在测试样本标号在[125, 140]时也有类似的情况可以证明。

表 4 预测结果对比

Table 4 Comparison of prediction results						
Model	R^2	R_{MSE}	R_{MAE}	Hit rate $H(-0.05-0.05)/\%$	Hit rate $H(-0.10-0.10)/\%$	
MIC+SHAP-Transformer	0.257 9	0.090 3	0.153 1	45.45	74.55	
Feature selection+LSTM	0.549 6	0.070 4	0.123 1	54.55	86.06	
Feature selection+SHAP-Transformer	0.783 7	0.048 8	0.082 4	72.12	95.76	

由表 4 可见,铁水硅含量的预测误差为 $-0.05 \sim 0.05$ 和 $-0.10 \sim 0.10$ 时,经过滑动窗口时滞分析及耦合参数优选的 SHAP-Transformer 模型的命中率分别为 72.12% 和 95.76%,比未经时滞分析及耦合参数优选的 SHAP-Transformer 模型命中率分别提升了 26.67% 和 21.21%,比 LSTM 模型命中率分别提升了 17.57% 和 9.7%。经过滑动窗口时滞分析及耦合参数优选的 SHAP-Transformer



(a) 基于 C_{imax} 选择的 SHAP-Transformer 模型; (b) 基于滑动窗口时滞分析及耦合参数优选的 LSTM 模型; (c) 基于滑动窗口时滞分析与耦合参数优选的 SHAP-Transformer 模型

图 8 铁水硅含量预测结果

Fig. 8 Predicted silicon content in hot metal

对铁水硅含量发生较大变化时的提前准确预警可以帮助操作人员及时处理异常炉况,维持高炉长期稳定顺行。

当测试样本标号在[75, 90]时,铁水硅含量波动较为平缓。对比图 8(b) 和(c) 可以看出,SHAP-Transformer 模型的预测结果与实测值更接近,而 LSTM 模型出现了过度平滑现象,这表明 SHAP-Transformer 模型可以捕捉到生产参数的细微变化特征,对炉况的变化更为敏感。

模型命中率最高,预测性能最佳。该模型与高炉冶炼工艺相结合,一方面考虑了高炉数据存在的强耦合、非线性、大时滞及多时间尺度特点,进行了耦合参数选择,采用基于随机森林优化 Shapley 值的算法降低了模型训练的复杂度;另一方面考虑了高炉炉况总是处于不断的变化中,引起铁水硅含量波动,在模型构建时采用了 Transformer 模型,并在其注意力机制引入 SHAP 算法优化,使模型在对近期

数据保持高度关注的同时,兼顾长期历史数据中铁水硅含量的变化规律。模型从特征选择和模型构建2个方面提高了预测精度。

4.2 铁水硅含量的变化趋势分析

为了提前把握炉温的走向,科学用好风温和喷吹煤调剂手段,了解铁水硅含量的变化趋势是高炉操作者关心的问题。本文采用M-K检验(mann-kendall test)方法分析模型在趋势预测方面的精度。M-K检验是一种广泛应用的非参数统计检验方法,它不依赖于数据的正态分布特征,也不容易受到少数异常值的影响,具有较高的定量化程度和较宽的适用范围^[41]。M-K检验是根据标准正态统计量 Z 值的大小来判断时间序列是否存在显著上升或下降趋势,如果给定一个时间序列数据 $X_1, X_2, \dots, X_n$,其中 X_i 表示第 i 时刻的观测值,则 Z 值的计算公

式为

$$Z = \frac{S_n}{\sigma_s} \tag{8}$$

$$S_n = \sum_{i=1}^{n-1} \sum_{j=i+1}^n \text{sgn}(X_j - X_i) \tag{9}$$

$$\sigma_s = \sqrt{\frac{n(n-1)(2n+5)}{18}} \tag{10}$$

式中:sgn为符号函数,当 $X_j > X_i$ 时为+1, $X_j < X_i$ 时为-1, $X_j = X_i$ 时为0; S_n 为统计量; n 为观测值的总个数; σ_s 为统计量的标准差。

当 Z 为正数时,表示数据呈上升趋势;当 Z 为负数时,表示数据呈下降趋势。 Z 值绝对值的大小表示趋势的显著程度。通过显著性水平和 Z 值的关系并结合现场经验,定义了铁水硅含量变化快速上升、缓慢上升、平稳、缓慢下降和快速下降5个趋势类别,不同趋势类别对应的 Z 值范围见表5。

表 5 Z 值与趋势类别的对应关系

Table 5 Correspondence between Z values and trend changes

Trend type	Sharp rise	Slow rise	Stable	Slow decrease	Sharp decrease
Range of Z -values	> 1.645	$[0.674, 1.645]$	$[-0.674, 0.674]$	$[-1.645, -0.674]$	< -1.645

以连续5次出铁为1组,从第5个样本标号开始,分别使用硅含量的实测值和训练好的基于滑动窗口时滞分析及耦合参数优选的SHAP-Transformer模型的预测值计算 Z 值,可以得到157组趋势类别样本,结果对比如图9所示。

由图9可见,实际类别与预测类别相同的有95组,比例为60.5%;类别不相同但趋势变化方向相

同的有137组,占87.3%。这主要是由于 Z 值的计算涉及连续5次出铁的预测值,如果其中某次出铁的预测值与实际值出现一定偏差,那么得到的 Z 值就会不同,造成趋势类别预测不准确。但总地来看,本模型在趋势变化方向的预测上表现良好,能够有效帮助操作者提前判断炉温变化趋势,并及时采取合适的操作措施,进而保持炉温的稳定性。




图 9 模型与实际趋势类别对比
Fig. 9 Comparison of trend categories

5 结论

1)采用时间窗口和PCA技术将22个分钟级特征参数转换为铁次级参数,与铁水硅含量检测时间尺度匹配;采用滑动窗口结合 C_{imax} 确定特征参数的

滞后时长;采用随机森林优化的SHAP算法分析34个参数在强耦合条件下的重要性排名,筛选出7个关键参数,通过特征选择的方式剔除冗余信息,提高了硅预报模型的训练速度和预测效果。

2)构建的SHAP-Transformer模型依靠Trans-

former的全局自注意力机制,增强了对长时间序列数据的建模能力,并且在自注意力机制中融入Shapley值权重矩阵,增强了模型对关键特征的关注度,为高炉铁水硅含量预报数据驱动型模型的构建提供了新方法。

3)基于时滞分析及耦合参数优选的SHAP-Transformer模型在铁水硅含量预测中具有明显优势,误差为 $-0.05\sim 0.05$ 和 $-0.10\sim 0.10$ 时的命中率分别为72.12%和95.76%,优于LSTM模型和 C_{imax} 选择模型。该模型对铁水硅含量变化趋势方向和趋势类别的预测准确率分别为87.3%及60.5%,能够满足高炉操作中提前判断炉温变化并及时进行调整的需求。

参考文献:

- [1] CHEN W, WANG B X, HAN H L. Prediction and control for Silicon content in pig iron of blast furnace by integrating artificial neural network with genetic algorithm[J]. Ironmaking and Steelmaking, 2009, 37(6): 458.
- [2] AZADI P, WINZ J, LEO E, et al. A hybrid dynamic model for the prediction of molten iron and slag quality indices of a large-scale blast furnace[J]. Computers and Chemical Engineering, 2022, 156: 107573.
- [3] LIMA M S M, ERYARSOY E. Predicting and explaining pig iron production on charcoal blast furnaces: a machine learning approach[J]. Informs Journal on Applied Analytics, 2021, 51(3): 213.
- [4] SAXÉN H, GAO C H, GAO Z W. Data-driven time discrete models for dynamic prediction of the hot metal silicon content in the blast furnace: a review[J]. IEEE Transactions on Industrial Informatics, 2013, 9(4): 2213.
- [5] SAXÉN H, PETTERSSON F. Nonlinear prediction of the hot metal silicon content in the blast furnace[J]. ISIJ International, 2007, 47(12): 1732.
- [6] CUI Z, YANG A, WANG L, et al. Dynamic prediction model of silicon content in molten iron based on comprehensive characterization of furnace temperature[J]. Metals, 2022, 12(9): 1403.
- [7] LAKSHMANAN K, KARIMI A, CARR A, et al. A hybrid modelling approach based on deep learning for the prediction of the silicon content in the blast furnace[J]. Procedia Computer Science, 2023, 225: 2204.
- [8] ZENG J S, GAO C H, SU H Y. Data-driven predictive control for blast furnace ironmaking process[J]. Computers and Chemical Engineering, 2010, 34(11): 1854.
- [9] 刘然, 高子扬, 李宏扬, 等. 高炉智能优化系统综述与展望[J]. 中国冶金, 2024, 34(3): 13. (LIU R, GAO Z Y, LI H Y, et al. Overview and prospect of intelligent optimization system for blast furnace[J]. China Metallurgy, 2024, 34(3): 13.)
- [10] 冯梦龙, 林路, 史亚彤, 等. 铁水预脱磷技术及其自动化模型研究进展[J]. 中国冶金, 2025, 35(5): 10. (FENG M L, LIN L, SHI Y T, et al. Research progress of hot metal pre-dephosphorization technology and its automatic model[J]. China Metallurgy, 2025, 35(5): 10.)
- [11] SU X L, SUN S L, ZHANG S, et al. Improved multi-layer online sequential extreme learning machine and its application for hot metal silicon content[J]. Journal of the Franklin Institute, 2020, 357(17): 12588.
- [12] LI Y J, ZHANG J, ZHANG S, et al. Dual ensemble online modeling for dynamic estimation of hot metal silicon content in blast furnace system[J]. ISA Transactions, 2022, 128: 686.
- [13] 刘小杰, 邓勇, 李欣, 等. 基于大数据技术的高炉铁水硅含量预测[J]. 中国冶金, 2021, 31(2): 10. (LIU X J, DENG Y, LI X, et al. Prediction of silicon content in hot molten of blast furnace based on big data technology[J]. China Metallurgy, 2021, 31(2): 10.)
- [14] 胡进, 郜传厚. 基于多任务学习的高炉热状态预测[J]. 中国冶金, 2023, 33(7): 81. (HU J, GAO C H. Thermal state prediction of blast furnace based on multi-task learning[J]. China Metallurgy, 2023, 33(7): 81.)
- [15] 赵志伟, 冯伟健, 邵玉杰, 等. 基于集成学习和工艺经验的烧结终点预报模型[J]. 冶金能源, 2024, 43(3): 44. (ZHAO Z W, FENG W J, SHAO Y J, et al. Prediction model of sintering burn through point based on integrated learning and process experience[J]. Energy for Metallurgical Industry, 2024, 43(3): 44.)
- [16] 李泽龙, 杨春节, 刘文辉, 等. 基于LSTM-RNN模型的铁水硅含量预测[J]. 化工学报, 2018, 69(3): 992. (LI Z L, YANG C J, LIU W H, et al. Research on hot metal Si-content prediction based on LSTM-RNN[J]. CIESC Journal, 2018, 69(3): 992.)
- [17] REN Y Z, XING X D, WANG B R, et al. Prediction model for silicon content of hot metal based on PSO-TCN[J]. Metallurgical and Materials Transactions B, 2024, 55(4): 2837.
- [18] 尹林子, 关羽吟, 蒋朝辉, 等. 基于k-means++的高炉铁水硅含量数据优选方法[J]. 化工学报, 2020, 71(8): 3661. (YIN L Z, GUAN Y Y, JIANG Z H, et al. Optimal method of selecting silicon content data in blast furnace hot metal based on k-means++[J]. CIESC Journal, 2020, 71(8): 3661.)
- [19] 邱国兴, 蔡明冲, 张毅, 等. 基于灰色关联分析和机器学习的高炉铁水硅含量预测[J]. 材料导报, 2024, 38(20): 252. (QIU G X, CAI M C, ZHANG Y, et al. Prediction of silicon content in blast furnace molten iron using grey correlation analysis and machine learning[J]. Materials Reports, 2024, 38(20): 252.)
- [20] 邓序之, 刘淇, 叶傲霜, 等. 基于气象耦合特征分析及改进XGBoost算法的用户分布式光伏短期出力预测模型[J]. 南方电网技术, 2023, 17(12): 80. (DENG X Z, LIU Q, YE A S, et al. Short-term output forecasting model of user side distributed photovoltaic based on meteorological coupling characteristics analysis and improved XGBoost algorithm[J]. Southern Power System Technology, 2023, 17(12): 80.)
- [21] NOH S H. Analysis of gradient vanishing of RNNs and per-

- formance comparison[J]. Information, 2021, 12(11):442.
- [22] 刘华玲, 何铁辉. LSTM 的季节性注意力及在文本情感分类中的应用[J]. 系统科学与数学, 2023, 43(4):1002. (LIU H L, HE Y H. LSTM altered by seasonal attention and its application in text sentiment classification[J]. Journal of Systems Science and Mathematical Sciences, 2023, 43(4):1002.)
- [23] 刘典, 秦勇, 杨伟君, 等. 基于未来可预知特征的高速列车变流器超温故障 KFF-LSTM 预测方法[J]. 中南大学学报(自然科学版), 2023, 54(8):3370. (LIU D, QIN Y, YANG W J, et al. KFF-LSTM high temperature fault prediction method using in high-speed rail train converter based on known future features[J]. Journal of Central South University(Natural Science), 2023, 54(8):3370.)
- [24] 陈俊英, 席月芸, 李朝阳. 多尺度局部特征和 Transformer 全局学习融合的发动机剩余寿命预测[J]. 自动化学报, 2024, 50(9):1818. (CHEN J Y, XI Y Y, LI Z Y. Prediction of aeroengine remaining life by combining multi-scale local features and transformer global learning[J]. Acta Automatica Sinica, 2024, 50(9):1818.)
- [25] 曹威, 王兴, 邹复民, 等. 融合多种时空自注意力机制的 Transformer 交通流预测模型[J]. 计算机系统应用, 2024, 33(4):82. (CAO W, WANG X, ZOU F M, et al. Transformer traffic flow prediction model integrating multiple spatiotemporal self-attention mechanisms[J]. Computer Systems and Applications, 2024, 33(4):82.)
- [26] 盛刚, 马子恒, 李帅兵. 智能决策对炼铁-炼钢界面铁水温降的影响[J]. 中国冶金, 2025, 35(2):65. (SHENG G, MA Z H, LI S B. Effect of intelligent decision on hot metal temperature drop in ironmaking-steelmaking interface[J]. China Metallurgy, 2025, 35(2):65.)
- [27] YU X B, SHEN Y S. Transient state modeling of industry-scale ironmaking blast furnaces[J]. Chemical Engineering Science, 2022, 248(Part A):117185.
- [28] 刘学艺, 刘祥官, 王文慧. 贝叶斯网络在高炉铁水硅含量预测中的应用[J]. 钢铁, 2005, 40(3):17. (LIU X Y, LIU X G, WANG W H. Application of bayesian network to predicting silicon content in hot metal[J]. Iron and Steel, 2005, 40(3):17.)
- [29] ROSTAMI T B, MIRCETIC D. Exploring the association between time series features and forecasting by temporal aggregation using machine learning[J]. Neurocomputing, 2023, 548:126376.
- [30] LI X J, YU D, SØREN B V, et al. The development of machine learning-based remaining useful life prediction for lithium-ion batteries[J]. Journal of Energy Chemistry, 2023, 82:103.
- [31] 胡怡然, 夏芳. 基于自注意力机制与 BiLSTM 的短文本匹配模型[J]. 武汉科技大学学报, 2023, 46(1):75. (HU Y R, XIA F. A short text matching model using self-attention mechanism and BiLSTM[J]. Journal of Wuhan University of Science and Technology, 2023, 46(1):75.)
- [32] LI J B, LIU P, CHEN L, et al. An integrated fusion framework for ensemble learning leveraging gradient-boosting and fuzzy rule-based models[J]. IEEE Transactions on Artificial Intelligence, 2024, 5(11):5771.
- [33] YING C H, LU J A. TFE former: temporal feature enhanced transformer for multivariate time series forecasting[J]. IEEE Access, 2024, 12:153694.
- [34] LIVIERIS I E, PINTELAS E, PINTELAS P. A CNN-LSTM model for gold price time-series forecasting[J]. Neural Computing and Applications, 2020, 32(23):17351.
- [35] JIANG Z Y, TAN Q M, LI N, et al. A novel BiGRU multi-step wind power forecasting approach based on multi-label integration random forest feature selection and neural network clustering[J]. Energy Conversion and Management, 2024, 319:118904.
- [36] 李福民, 董钰泽, 刘颂, 等. 基于 RFE-DNN 的烧结矿性能预警模型[J]. 冶金能源, 2023, 42(5):3. (LI F M, DONG Y Z, LIU S, et al. Early warning model of sinter performance based on RFE-DNN[J]. Energy for Metallurgical Industry, 2023, 42(5):3.)
- [37] 崔桂梅, 陈荣, 于凯, 等. 基于多尺度分解的 ELM 炉温预测研究[J]. 控制工程, 2020, 27(11):1901. (CUI G M, CHEN R, YU K, et al. The study on temperature prediction of ELM furnace based on multiscale decomposition[J]. Control Engineering of China, 2020, 27(11):1901.)
- [38] 罗世华, 陈坤. 基于偏态深度分类的高炉硅含量及波动预测[J]. 控制与决策, 2021, 36(2):491. (LUO S H, CHEN K. Prediction of blast furnace Silicon content and fluctuation based on skewness depth classification[J]. Control and Decision, 2021, 36(2):491.)
- [39] BAKHT M P, MOHD M N H, IBRAHIM B S K K, et al. Advanced automated machine learning framework for photovoltaic power output prediction using environmental parameters and SHAP interpretability[J]. Results in Engineering, 2025, 25:103838.
- [40] WANG D, THUNÉLL S, LINDBERG U, et al. Towards better process management in wastewater treatment plants: process analytics based on SHAP values for tree-based machine learning methods[J]. Journal of Environmental Management, 2022, 301:113941.
- [41] 毛远宏, 孙琛琛, 徐鲁豫, 等. 基于深度学习的时间序列预测方法综述[J]. 微电子学与计算机, 2023, 40(4):8. (MAO Y H, SUN C C, XU L Y, et al. A survey of time series forecasting methods based on deep learning[J]. Microelectronics and Computer, 2023, 40(4):8.)
- [42] VASWANI A, SHAZEER N, PAEMAE N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30:5999.
- [43] GIANNETTI C, BORGHINI E, CARR A, et al. Deep learning for robust forecasting of hot metal silicon content in a blast furnace[J]. The International Journal of Advanced Manufacturing Technology, 2025, 136(9):4045.
- [44] 邹霞. 基于 WQI 的河网水系水质评价及时空特性分析[J]. 水电能源科学, 2024, 42(4):53. (ZOU X. WQI based water quality assessment and spatial-temporal variation analysis in river network[J]. Water Resources and Power, 2024, 42(4):53.)